

1 - Limpieza e Integración

En esta unidad, exploraremos las técnicas fundamentales para la limpieza de datos, enfocándonos en la detección y tratamiento de valores faltantes y outliers. Además, reforzaremos la integración de múltiples fuentes de datos, abordando la conciliación de formatos y claves para preparar datasets robustos para análisis y modelado. Finalmente, conoceremos herramientas prácticas y librerías en Python y plataformas de la industria que facilitan estos procesos, preparando el camino para flujos automatizados de preprocesamiento.

¿Alguna vez te has encontrado con un conjunto de datos incompleto o con valores que parecen no encajar? Estos problemas son comunes en análisis de datos y pueden afectar la calidad de tus modelos predictivos. En esta unidad, aprenderás a detectar y tratar valores faltantes y outliers, dos desafíos frecuentes en la limpieza de datos.

Además, reforzaremos cómo integrar datos provenientes de distintas fuentes, conciliando formatos y claves para obtener un dataset coherente y listo para el análisis. Utilizaremos ejemplos prácticos con Python y Pandas, herramientas estándar en la industria, y conocerás plataformas que automatizan estos procesos, facilitando tu flujo de trabajo.

Al finalizar, estarás preparado para manejar datos reales con mayor confianza y precisión, un paso clave en cualquier proyecto de Data Science.

Limpieza de Datos: Valores Faltantes y Outliers

La **limpieza de datos** es un paso esencial para garantizar la calidad y confiabilidad de cualquier análisis. Dos problemas comunes son los *valores faltantes* y los *outliers*.

Valores Faltantes

Los valores faltantes (**missing values**) son datos ausentes en un dataset. Pueden deberse a errores de captura, problemas técnicos o simplemente a la ausencia de información.

Técnicas de Imputación

- **Imputación con media:** Reemplaza valores faltantes con la media de la variable.

- **Imputación con mediana:** Útil cuando la variable tiene valores extremos, ya que la mediana es más robusta.
- **Imputación avanzada:** Métodos como K-Nearest Neighbors (KNN) o modelos predictivos que estiman valores faltantes basados en otras variables.

Nota: La elección de la técnica depende del contexto y la naturaleza de los datos.

Outliers

Los *outliers* son valores atípicos que se desvían significativamente del resto de los datos. Pueden ser errores o datos válidos pero extremos.

Detección y Tratamiento

- **Detección:** Métodos estadísticos (z-score, IQR), visualizaciones (boxplots).
- **Tratamiento:** Eliminación, transformación o imputación según el caso.

Integración de Fuentes

La integración consiste en combinar datos de diferentes orígenes para un análisis unificado.

Técnicas de Unión

- **Joins y merges:** Operaciones para combinar datasets basados en claves comunes.

Gestión de Formatos y Claves

- Normalización de formatos (fechas, categorías).
- Resolución de conflictos en claves y duplicados.

Herramientas Prácticas

- **Python y Pandas:** Librerías para manipulación y limpieza de datos.
- **scikit-learn:** Ofrece funciones para imputación avanzada.
- **Power BI y Jupyter Notebooks:** Plataformas para análisis y visualización.



> Estas herramientas permiten implementar flujos de trabajo eficientes y reproducibles en proyectos reales.

En la práctica, los datos raramente llegan limpios y listos para el análisis. Por ejemplo, en un proyecto de análisis de ventas, podrías recibir información de diferentes sucursales con formatos distintos y registros incompletos. Aplicar técnicas de imputación adecuadas evita sesgos y pérdida de información valiosa. Detectar outliers puede revelar errores de captura o eventos excepcionales que merecen atención especial.

La integración de fuentes es crucial cuando se combinan datos de CRM, sistemas de inventario y plataformas de marketing. Saber manejar joins y merges correctamente asegura que la información se consolide sin perder coherencia.

Herramientas como Pandas facilitan estas tareas con funciones específicas para detectar valores faltantes (`isnull()`), imputar datos (`fillna()`), y combinar datasets (`merge()`). Plataformas como DataRobot o Trifacta ofrecen automatización basada en IA para acelerar estos procesos, permitiendo enfocarse en el análisis y la interpretación.

Este conocimiento es fundamental para preparar datos que alimenten modelos predictivos confiables y para mantener la integridad en proyectos de Data Science en la industria.

En esta unidad, aprenderás a estructurar notebooks y entornos en Jupyter y Google Colab para crear pipelines de análisis reproducibles. Cubriremos las mejores prácticas para organizar el flujo de trabajo, documentar el proceso, gestionar dependencias y conectar almacenamiento en la nube, asegurando que tus análisis sean claros, replicables y colaborativos.

¿Alguna vez has intentado replicar un análisis de datos y te has encontrado con notebooks desordenados, dependencias rotas o resultados inconsistentes? En el mundo profesional de la ciencia de datos, la reproducibilidad es clave para garantizar que los análisis sean confiables, colaborativos y escalables. En esta unidad, exploraremos cómo diseñar pipelines reproducibles utilizando Jupyter y Google Colab, dos herramientas ampliamente usadas en la industria. Aprenderás a estructurar tus notebooks para que sean claros y fáciles de seguir, documentar cada paso del proceso, gestionar dependencias y conectar tu trabajo con almacenamiento en la nube para facilitar el acceso y la colaboración. Al finalizar, estarás preparado para crear flujos de trabajo que no solo funcionen en tu entorno, sino que puedan ser replicados por otros sin inconvenientes, un requisito fundamental en proyectos reales de ciencia de datos.

2- Medidas de Tendencia y Dispersión

En esta unidad, exploraremos las bases de la estadística descriptiva enfocándonos en las medidas de tendencia central y dispersión. Aprenderás a calcular e interpretar la media, mediana, moda, varianza, desviación estándar, cuartiles y percentiles utilizando Python y librerías como Pandas y NumPy. Además, entenderás cómo estas métricas aportan valor en el análisis de datos para la toma de decisiones en contextos reales de negocio.

¿Alguna vez te has preguntado cómo resumir grandes conjuntos de datos para entender rápidamente su comportamiento?

En el análisis de datos, las **medidas de tendencia central y dispersión** son herramientas fundamentales que nos permiten describir y resumir la información de manera efectiva. En esta unidad, descubrirás cómo calcular y aplicar estas medidas usando Python y librerías como Pandas y NumPy, facilitando la interpretación de datos en contextos reales de negocio.

Al finalizar, estarás capacitado para generar reportes claros que apoyen la toma de decisiones basadas en datos.

En la práctica profesional, la estadística descriptiva es la base para cualquier análisis de datos. Por ejemplo, un analista de datos en una empresa de retail puede usar la media y desviación estándar para entender el comportamiento promedio de ventas y su variabilidad, lo que ayuda a identificar patrones o anomalías.

Además, conocer la mediana es crucial cuando los datos tienen valores extremos, como ventas muy altas en días especiales, que podrían distorsionar la media.

Estas técnicas también son esenciales para preparar los datos antes de aplicar modelos predictivos, asegurando que comprendemos bien la información con la que trabajamos. En los próximos módulos, aplicaremos estas medidas usando Python y librerías como pandas y NumPy para manipular y analizar conjuntos de datos reales.

Amplia biblioteca especializada:

Python cuenta con librerías potentes para cada etapa del análisis:

- Pandas para manipulación y limpieza de datos.
- NumPy para cálculos numéricos.
- Matplotlib y Seaborn para visualización.
- Scikit-learn para machine learning. Esto reduce el tiempo de desarrollo y facilita tareas complejas.
- **Facilidad de aprendizaje y sintaxis clara:** su sintaxis es simple y legible, lo que permite que analistas y científicos de datos se enfoquen en el análisis sin perder tiempo en detalles técnicos.
- **Integración con otras herramientas:** se integra fácilmente con:
Bases de datos (SQL, NoSQL).
- **APIs y servicios web:** se conecta fácilmente con herramientas de data visualization como Tableau o Power BI. Esto lo convierte en un puente entre diferentes sistemas.
- **Gran comunidad y soporte:** hay una comunidad enorme que genera documentación, tutoriales y soluciones. Esto significa que cualquier problema tiene alta probabilidad de estar resuelto en foros como Stack Overflow.
- **Escalabilidad y automatización:** permite automatizar procesos repetitivos y escalar análisis desde datasets pequeños hasta grandes volúmenes de datos, incluso integrando con Big Data y Cloud.

Python como herramienta clave para usar en análisis de datos



Estadística Descriptiva

La *estadística descriptiva* es el conjunto de técnicas que nos permiten **resumir y describir las características principales de un conjunto de datos**, enfocándose en aspectos centrales y la variabilidad.

Características de la Estadística Descriptiva:




Medidas de Tendencia Central

Estas medidas indican el valor central o típico de una distribución:

- **Media:** Promedio aritmético de los datos. Se calcula sumando todos los valores y dividiendo entre el número total de observaciones.
- **Mediana:** Valor que divide el conjunto de datos ordenados en dos partes iguales. Es menos sensible a valores extremos que la media.
- **Moda:** Valor que aparece con mayor frecuencia en el conjunto de datos.

Ejemplo: En ventas mensuales, la media indica el promedio de ventas, la mediana muestra el punto medio y la moda puede indicar el valor más común de ventas.



Medidas de Dispersión

Cuantifican la variabilidad o dispersión de los datos:

- **Varianza (σ^2):** Promedio de las diferencias al cuadrado entre cada dato y la media.
- **Desviación estándar (σ):** Raíz cuadrada de la varianza, expresa la dispersión en las mismas unidades que los datos.
- **Rango intercuartílico (IQR):** Diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), mide la dispersión en la mitad central de los datos.

Cuartiles y Percentiles

Dividen la distribución en segmentos para analizar posiciones relativas:

- **Cuartiles:** Dividen los datos en cuatro partes iguales.
- **Percentiles:** Dividen los datos en 100 partes iguales, útiles para entender la posición relativa de un dato.

Por ejemplo, el percentil 90 indica que el 90% de los datos están por debajo de ese valor.

Herramientas Prácticas

Para implementar estas medidas, usaremos:

- **Python** con librerías:
- **Pandas**: manejo y análisis de datos tabulares.
- **NumPy**: operaciones numéricas y estadísticas.
- **Jupyter Notebooks**: entorno interactivo para combinar código, visualizaciones y texto.



Estas herramientas permiten calcular rápidamente las medidas y facilitar la interpretación en contextos reales.

En la industria del análisis de datos, comprender y aplicar correctamente las medidas de tendencia central y dispersión es esencial para describir conjuntos de datos y detectar patrones o anomalías. Por ejemplo, en un análisis de ventas, conocer la media y desviación estándar ayuda a identificar meses con rendimiento atípico.

Además, el uso de cuartiles y percentiles es común en la segmentación de clientes, donde se clasifican según su comportamiento o valor.

El dominio de estas técnicas con herramientas como Pandas y NumPy permite automatizar reportes y análisis exploratorios, facilitando la comunicación efectiva con equipos de negocio y la toma de decisiones basada en datos.

Esta unidad prepara el terreno para el análisis exploratorio de datos más avanzado y el preprocesamiento que abordaremos en la siguiente unidad.

3- Distribuciones y Correlación

En esta unidad exploraremos las distribuciones de datos más comunes, como la normal y la uniforme, y aprenderemos a visualizarlas mediante histogramas y diagramas de densidad en Jupyter Notebooks.

Además, profundizaremos en el concepto de correlación, calculando el coeficiente de Pearson con Pandas, interpretando sus resultados y entendiendo sus limitaciones, especialmente la diferencia entre correlación y causalidad. Esta base es esencial para realizar análisis exploratorios efectivos que guíen el preprocesamiento y modelado en proyectos de ciencia de datos.


¿Alguna vez te has preguntado cómo se distribuyen realmente los datos que analizas? Entender la forma y características de una distribución es fundamental para interpretar correctamente cualquier conjunto de datos y tomar decisiones informadas en ciencia de datos.

En esta unidad, aprenderemos a identificar distribuciones comunes como la normal y la uniforme, y a visualizarlas eficazmente usando histogramas y diagramas de densidad en Jupyter Notebooks con Python.

Además, exploraremos cómo medir la relación entre variables mediante el coeficiente de correlación de Pearson, una herramienta clave para detectar patrones y asociaciones en datos reales.

Exploratory Data Analysis (EDA)

In Data Science with Python, understanding **distributions and correlation** is the foundation of exploratory data analysis.



Distribuciones Comunes: Normal y Uniforme

En estadística, una *distribución* describe cómo se dispersan o agrupan los valores de una variable. Dos distribuciones teóricas fundamentales son:

- **Distribución Normal:** También conocida como distribución gaussiana, es simétrica y tiene forma de campana. Muchos fenómenos naturales y mediciones siguen esta distribución, lo que la hace crucial en inferencia estadística.
- **Distribución Uniforme:** Todos los valores dentro de un rango tienen la misma probabilidad. Representa dispersión homogénea sin concentración en valores específicos.

Ejemplo industrial: En análisis de calidad, la distribución normal puede modelar variaciones en medidas de producción, mientras que la uniforme puede representar selección aleatoria de muestras.

Visualización con Histogramas

Un **histograma** es un gráfico que muestra la frecuencia de valores en intervalos (bins). Permite identificar:

- La forma general de la distribución (simétrica, sesgada, multimodal)
- Concentraciones o vacíos en los datos

En Python, con `matplotlib` o `seaborn`, podemos crear histogramas fácilmente. Por ejemplo:

```
python
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
df = pd.read_csv('datos.csv')
sns.histplot(df['variable'], bins=30, kde=True)
plt.show()
```

El parámetro `kde=True` añade un diagrama de densidad para suavizar la visualización.

Correlación: Medición de Relaciones Lineales

La **correlación** cuantifica la relación lineal entre dos variables. El coeficiente de **Pearson** es el más común, con valores entre -1 y 1:

- 1: correlación positiva perfecta
- 0: sin correlación lineal
- -1: correlación negativa perfecta

***Nota:** Correlación no implica causalidad. Dos variables pueden estar correlacionadas por coincidencia o por una tercera variable.*

En Pandas, calculamos la correlación así:

```
python
corr = df['var1'].corr(df['var2'])
print(f'Coeficiente de Pearson: {corr:.2f}')
```

Este valor ayuda a identificar variables que podrían influirse mutuamente o compartir patrones comunes, útil para selección de características y análisis exploratorio.

Conocimientos clave:

Concepto	Definición breve
Distribución normal	Distribución simétrica en forma de campana
Distribución uniforme	Distribución con probabilidad constante en rango
Histograma	Gráfico de frecuencias para visualizar distribuciones
Correlación Pearson	Medida de relación lineal entre dos variables

En la práctica del análisis de datos, reconocer la forma de la distribución de una variable permite anticipar comportamientos y seleccionar técnicas adecuadas para su tratamiento. Por ejemplo, variables con distribución sesgada pueden requerir transformaciones antes de modelar.

Los histogramas y diagramas de densidad son herramientas visuales esenciales para esta tarea, facilitando la detección de patrones, valores atípicos y multimodalidad.

Por otro lado, el análisis de correlación ayuda a entender cómo se relacionan las variables entre sí, lo que es fundamental para la selección de características y para evitar problemas como la multicolinealidad en modelos predictivos.

En entornos industriales, estas técnicas se aplican para:

- Diagnosticar calidad de datos en sensores o registros de producción
- Identificar variables clave que afectan resultados de negocio
- Guiar decisiones de limpieza y transformación de datos

Este conocimiento es la base para el siguiente módulo, donde se abordarán técnicas de preprocesamiento basadas en los insights obtenidos en el análisis exploratorio.

4- Transformación y Reducción

En esta unidad, exploraremos técnicas clave para transformar y reducir datos en el preprocesamiento, incluyendo normalización, escalado, codificación categórica y reducción de dimensionalidad con PCA. Además, conoceremos herramientas basadas en IA que automatizan y optimizan estos procesos, facilitando flujos de trabajo eficientes en ciencia de datos.

¿Alguna vez te has preguntado cómo preparar tus datos para que los modelos predictivos funcionen de manera óptima?

La transformación y reducción de datos son pasos fundamentales para garantizar que los algoritmos interpreten correctamente la información y produzcan resultados confiables.

En esta unidad, aprenderás a aplicar técnicas de normalización y escalado para homogeneizar las magnitudes de tus variables, codificar variables categóricas para que sean entendibles por modelos matemáticos y reducir la dimensionalidad de tus datos con PCA, preservando la mayor cantidad de información posible.

Además, exploraremos cómo la inteligencia artificial y herramientas especializadas pueden automatizar y acelerar estos procesos, permitiéndote enfocarte en el análisis y la interpretación. Al finalizar, estarás capacitado para implementar pipelines de preprocesamiento eficientes y adaptados a tus necesidades, utilizando Python y librerías reconocidas en la industria.

Transformación de Datos: Normalización y Escalado

La **transformación de datos** es esencial para preparar variables con diferentes magnitudes y unidades para su análisis. Dos técnicas comunes son:

- **Escalado Min-Max:** Reescala los datos para que estén dentro de un rango específico, típicamente [0,1].
$$[x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}]$$
- **Escalado Estándar (StandardScaler):** Centra los datos en la media 0 y desviación estándar 1.
$$[x' = \frac{x - \mu}{\sigma}]$$

¿Por qué es importante? Algunos algoritmos, como regresión logística, SVM o KNN, son sensibles a la escala de las variables y pueden verse sesgados si no se normalizan.

Codificación Categórica

Las variables categóricas deben convertirse a formato numérico para ser procesadas por modelos. Las técnicas principales son:

- **One-Hot Encoding:** Crea una columna binaria para cada categoría.
- **Target Encoding:** Asigna a cada categoría el valor promedio de la variable objetivo, útil en problemas supervisados.

Ejemplo: La variable "Color" con categorías {Rojo, Azul, Verde} se convierte en tres columnas binarias con one-hot encoding.

Reducción de Dimensionalidad con PCA

El **Análisis de Componentes Principales (PCA)** es una técnica lineal que proyecta datos en un espacio de menor dimensión preservando la mayor varianza posible.

- Permite simplificar modelos y visualizar datos complejos.
- Se basa en calcular vectores propios y valores propios de la matriz de covarianza.

PCA es especialmente útil cuando se trabaja con datasets con muchas variables, ayudando a evitar el sobreajuste y mejorar la interpretabilidad.

Automatización del Preprocesamiento con IA

Herramientas como **DataRobot**, **Trifacta** y **Power BI con Copilot** integran inteligencia artificial para:

- Detectar automáticamente valores faltantes y outliers.
- Sugerir transformaciones y codificaciones.
- Construir pipelines de preprocesamiento optimizados.

Estas soluciones aceleran el flujo de trabajo y reducen errores manuales, permitiendo a los científicos de datos enfocarse en la interpretación y modelado avanzado.

En la práctica, la transformación y reducción de datos son pasos que se integran en pipelines de preprocesamiento para garantizar que los modelos reciban datos limpios, homogéneos y relevantes. Por ejemplo, al trabajar con un dataset de clientes que incluye edades, ingresos y categorías de productos preferidos, es necesario escalar las variables numéricas para que tengan igual peso y codificar las categorías para que los modelos las entiendan.

Además, cuando el dataset tiene muchas variables, aplicar PCA ayuda a reducir la complejidad sin perder información crítica, facilitando la visualización y mejorando la eficiencia computacional.

Las herramientas de automatización basadas en IA permiten implementar estos procesos de forma rápida y reproducible, integrándose con entornos como Jupyter Notebooks y plataformas de BI, lo que es especialmente valioso en entornos empresariales donde el tiempo y la precisión son cruciales.