

Guía del Proyecto: Pipeline Profesional de Ciencia de Dato

Este documento técnico detalla los bloques mandatorios para el desarrollo y evaluación del proyecto. El objetivo es demostrar rigurosidad metodológica, control de calidad de datos y alineación con los objetivos organizacionales.

Bloque 1: Contexto y Problema de Negocio

El proyecto no comienza con código, sino con una necesidad. El alumno debe definir el marco del problema.

El Problema: Explicar el impacto de la pérdida de usuarios/clientes (Churn) o, en escenarios públicos, el impacto de no predecir movimientos demográficos (como la tasa de natalidad) para la asignación de presupuestos.

- **Impacto Económico/Social:** * Costo de Adquisición vs. Costo de Retención.
- Simulación financiera: Si el cliente promedio aporta ARS 15.000/mes y el churn es del 5%, ¿cuánto dinero se pierde al año?
- **KPIs del Bloque:** El evaluador buscará métricas claras: *Churn Rate*, *Customer Lifetime Value (CLV)*, e *Impacto Económico Retenido Estimado*.

(Ejemplo)

Situación: Una empresa de telecomunicaciones detecta una pérdida acelerada de clientes en el último trimestre.

"El objetivo de este proyecto es mitigar la pérdida de clientes (*churn*) en nuestra cartera de servicios de fibra óptica, la cual actualmente presenta una tasa de abandono mensual del 5.5%. Financieramente, adquirir un cliente nuevo (CAC) nos cuesta ARS 45.000, mientras que el ingreso mensual promedio por usuario (ARPU) es de ARS 15.000.

Si logramos desarrollar un modelo predictivo que identifique al 75% de los usuarios en riesgo antes de que soliciten la baja, el equipo de retención podrá intervenir con un descuento del 20% por 6 meses (Costo de campaña: ARS 3.000/mes). Esto transformará una pérdida potencial de millones de pesos en ingresos retenidos, optimizando el Retorno de Inversión (ROI) de las campañas de marketing."

 **Conexión Social:** En el ámbito público, esto equivale a predecir la caída de la natalidad en un municipio: permite redireccionar el presupuesto de infraestructura (jardines de infantes) hacia programas de asistencia médica primaria en zonas que sí registran crecimiento.



Bloque 2: Dataset y Origen de los Datos

Declaración de la materia prima del proyecto.

Ficha Técnica del Dataset: Origen (Kaggle, datos.gob.ar, etc.), volumen inicial (filas x columnas) y descripción semántica de las variables clave.

Estrategia de Partición Inmediata: Explicar que para evitar el sesgo de selección, el dataset se divide en *Train* y *Test* (Holdout) **antes** de cualquier manipulación profunda o cálculo de estadísticas.

(Ejemplo)

"Para este desarrollo utilizamos el dataset público *Telco-Customer-Churn* extraído de Kaggle. El mismo cuenta con **7.043 registros y 21 variables** (features). La variable objetivo es *Churn* (Yes/No).

Como buena práctica de gobierno de datos y para garantizar una evaluación justa, lo primero que realizamos es una partición del dataset utilizando un 80% para entrenamiento (*x_train, y_train*) y un 20% para testeo final (*x_test, y_test*), el cual permanecerá aislado de todo el proceso de análisis y preprocesamiento."



Bloque 3: Exploratory Data Analysis (EDA)

Diagnóstico clínico de los datos de entrenamiento. El evaluador buscará gráficos e interpretaciones, no solo código ejecutado.

Análisis del Target: Demostrar si existe desequilibrio de clases (ej. 90% activos, 10% churn) y cómo afectará a la métrica de evaluación.

Patrones de Faltantes (Missingness): Uso visual de `missingno` para determinar si los datos faltan de forma completamente aleatoria (MCAR) o si están correlacionados con otra variable o el target.

Análisis de Distribución: Comparativa de variables numéricas respecto al target usando gráficos de densidad o *boxplots* (ej. verificar si la permanencia `tenure_months` es menor en los usuarios que abandonan).

(Ejemplo)

"Al analizar la variable objetivo, detectamos un fuerte desbalance de clases: el **73.4%** de los clientes permanecen activos, mientras que el **26.6%** abandonaron el servicio. Esto nos indica que la métrica *Accuracy* (Exactitud) no será confiable para medir el modelo.

Utilizando la librería `missingno`, observamos que la variable `TotalCharges` presenta 11 valores faltantes. Al cruzar estos registros con la variable `tenure` (meses de antigüedad), descubrimos que todos tienen `tenure = 0` (clientes nuevos que aún no han facturado). Por lo tanto, el patrón de *missingness* no es aleatorio (MNAR).

Al graficar la densidad de la antigüedad según el Churn, confirmamos la hipótesis de negocio: el riesgo de fuga se concentra críticamente en los **primeros 5 meses** de contrato."

Bloque 4: Preprocesamiento y ETL (Feature Engineering)

Diseño de la ingeniería de atributos y la preparación de los datos mediante un Pipeline reproducible.

Feature Engineering: Justificar la creación de nuevas variables (ej. ratios de consumo, binarizaciones) que ayuden al modelo a capturar relaciones no lineales.

Arquitectura de `construir_preprocesador()`:

Numéricas: Imputación por mediana (robustez ante outliers) + `StandardScaler()`.

Categorías de baja cardinalidad: `OneHotEncoder(drop='first', sparse_output=False)` para evitar colinealidad.

Categorías de alta cardinalidad: `TargetEncoder()` para mitigar la maldición de la dimensionalidad.

Control de Calidad (No Leakage): Explicar explícitamente cómo el uso de Pipeline de Scikit-Learn asegura que el escalado y el target encoding se calculen *dentro* de cada fold de la validación cruzada, evitando la filtración de datos de test.

(Ejemplo)

"Para preparar los datos de manera reproducible y evitar el *Data Leakage*, encapsulamos todo el preprocesamiento en la función `construir_preprocesador()` mediante un `ColumnTransformer` de Scikit-Learn:

- **Variables Numéricas (`tenure`, `MonthlyCharges`):** Imputamos los nulos con la mediana (robusta a outliers) y aplicamos `StandardScaler` debido a que la Regresión Logística es sensible a las diferencias de escala.
- **Variables Categóricas Cortas (`Gender`, `InternetService`):** Aplicamos `OneHotEncoder(drop='first')` para evitar la colinealidad.
- **Variables de Alta Cardinalidad (`PaymentMethod`):** Empleamos `TargetEncoder`. Al estar metido dentro del objeto Pipeline, garantizamos que el cálculo del promedio del target se realice *exclusivamente* en los folds de

entrenamiento de la validación cruzada, previniendo que el modelo 'vea' información del set de testeo."

Bloque 5: Modelado y Optimización

La búsqueda del modelo óptimo partiendo de la simplicidad.

El Baseline: Uso de `LogisticRegression` como punto de partida interpretable.

El Modelo Complejo: Uso de `RandomForestClassifier` para capturar interacciones no lineales.

Estrategia de Optimización: `GridSearchCV` acoplado con `StratifiedKfold` (para mantener la proporción de clases). La métrica de optimización principal en la grilla será `roc_auc`.

(Ejemplo)

"Establecemos una Regresión Logística como **Modelo Baseline**, obteniendo un ROC AUC inicial de **0.803** en validación cruzada.

Luego, entrenamos un `RandomForestClassifier` para capturar relaciones no lineales. Para tunear sus hiperparámetros, ejecutamos un `GridSearchCV` con un esquema de `StratifiedKfold(n_splits=5)` para respetar el desbalance del 26.6% del target en cada iteración. La grilla evalúa combinaciones de `n_estimators` [100, 200] y `max_depth` [5, 10], optimizando la métrica `roc_auc`."

Bloque 6: Evaluación Avanzada

Demostrar el rendimiento real del modelo frente a los datos retenidos (*Test Set*).

- **Métricas Globales:** Análisis exhaustivo combinando:
 - `Classification Report`: Precision, Recall y F1-Score para la clase positiva (Churn).
 - Matriz de Confusión: Conteo de Falsos Positivos y Falsos Negativos.
 - Curva ROC y Precision-Recall Curve: Especialmente útil si el desbalance de clases es severo.
- **Traducción al Negocio:** ¿Qué umbral de decisión elegir?
 - Si el costo de retención es bajo, se prioriza **Recall** (capturar más clientes en riesgo, tolerando falsos positivos).
 - Si la campaña es costosa, se busca mayor **Precision**.

(Ejemplo)

"Al evaluar el modelo optimizado de RandomForest contra el *Test Set* (datos nunca antes vistos), obtuvimos las siguientes métricas clave:

- **ROC AUC:** 0.842 (una mejora del 4% respecto al baseline).
- **Matriz de Confusión e Impacto de Negocio:** El modelo logró un **Recall del 78%** para la clase Churn. Esto significa que de 100 clientes que se iban a ir, detectamos a 78.

Sin embargo, la **Precision** es del 62% (tenemos un 38% de Falsos Positivos). Dado que el costo de la campaña de retención (un descuento) es sustancialmente menor que el costo de perder al cliente por completo (ARS 3.000 vs. ARS 45.000), el negocio convalida este umbral: preferimos absorber el costo de otorgar beneficios a algunos clientes estables a cambio de asegurarnos de frenar la fuga del 78% de los que sí estaban en riesgo."

○

❏ Bloque 7: Conclusiones y Próximos Pasos

El cierre que defiende el trabajo ante un comité de evaluación o dirección.

- **Interpretabilidad:** Análisis de las variables más importantes (*Feature Importances* del RandomForest) para entender qué dispara las alertas.
- **Retorno de Inversión (ROI):** Estimación de cuánto presupuesto se salvó o se redireccionó eficientemente gracias al 70-80% de detección del modelo.
- **Riesgos Detectados:** Advertencias sobre posibles fuentes de inestabilidad (ej. si cambian las condiciones macroeconómicas o si hay desfase temporal en los datos).

(Ejemplo)

"El proyecto demuestra viabilidad técnica y financiera. El análisis de *Feature Importances* determinó que las variables más influyentes para el modelo son el **tipo de contrato (mes a mes)** y los **cargos mensuales**.

Recomendación estratégica: El presupuesto de retención no debe atomizarse; debe redireccionarse e inyectarse agresivamente en usuarios que contratan el servicio bajo la modalidad mensual y que experimentan aumentos en sus facturas durante sus primeros 90 días.

Riesgo identificado: Si la situación macroeconómica del país empuja a un cambio masivo en los patrones de consumo, el modelo requerirá un reentrenamiento (Data Drift) en un plazo no mayor a 6 meses."